

Optimizacija vektorskih baza podataka

Empirijska evaluacija indeksnih struktura i kvantizacijskih tehnika


Student: Adi Kadušić, II-134

Predmet: Optimizacija baza podataka | **Profesor:** v. prof. dr. Denis Čeke

Studij: Softversko inženjerstvo, II ciklus studija

Institucija: Politehnički fakultet, Univerzitet u Zenici

Datum: Juni 2026.




Zašto milijardu vektora gazi standardne baze podataka?

- 768-dimenzionalni float32 vektor = **3 KB**; **milijarda vektora** premašuje **3 TB**.
- Iscrpna pretraga **skalira** $O(n)$ – potpuno nepraktično za web-razmjerne kolekcije.
- **Prokletstvo dimenzionalnosti** čini klasične indeksne strukture izuzetno sporim i neupotrebljivim.
- Rješenje: **aproksimativne metode (ANN)** koje biraju kompromis između brzine i tačnosti.

Brute Force



ANN



Četiri konfiguracije pod lupom: Indeksi i kompresija

Flat

Iscrpna pretraga | Bez kompresije | FAISS

IVF

Klaster-baziran | Bez kompresije | FAISS

IVF-PQ

Klaster-baziran | Produktna kvantizacija | FAISS


HNSW

Graf-baziran | Bez kompresije | Qdrant

3 istraživačke hipoteze • **500.000** pasusa • **1.000** upita po konfiguraciji


Kako rade HNSW i IVF mehanizmi?

HNSW



- Višeslojna grafovska hijerarhija (sloj 0 posjeduje sve vektore).
- Pohlepna navigacija od vrha prema dnu, složenost $O(\log n)$.
- Parametri: $M=16$ (veze), $ef_construct=200$, $ef_search=128$.

IVF



- k-means dijeli cjelokupan prostor na $K=256$ odvojenih klastera.
- Pretraga se limitira na $nprobe=32$ najbližih Voronoi ćelija.
- Broj usporedbi radikalno pada sa $O(n)$ na $O(n \cdot nprobe / K)$.

Rigorozan i standardizovan eksperimentalni postav

DATASET	MODEL
MS MARCO v2.1 500.000 pasusa 1.000 upita	all-mpnet-base-v2 768-dim vektori L2-normalizovani
HARDVER	METODOLOGIJA
Intel i7-14650HX 32 GB RAM RTX 4070 Ubuntu 24.04	Latencija, Recall@10, Memorija 5.000 mjerenja Wilcoxon test


IVF-PQ je 47× brži od Flat-a, ali gubi tačnost

Konfiguracija	Mean (ms)	Recall@10	P95 (ms)
Flat	52,36	1,0000	54,6
IVF	8,58	0,9564	9,5
HNSW	7,25	0,9972	44,1 !
IVF-PQ	1,12	0,6679	1,2

! HNSW: medijana sjajna, ali rep distribucije latencije (P95) problematičan pod opterećenjem.

IVF-PQ komprimira 40x – ali memorija nije jedini trošak


Memory Footprint by Index Configuration



IVF-PQ: Kompresija **40,88x** ✓ |
Pad tačnosti **33,21 pp** ✗

Uzrok: Agresivni parametri (M=64 pod-vektora, 8 bita). Svaki potprostor nezavisno akumulira kvantizacijsku grešku.

HNSW apsolutno dominira na Recall-Latency krivulji



IVF: Linearan kompromis
(latencija 2→33 ms donosi recall 0,88→0,99).

HNSW: Ekstremna strmina
(ef_search 50→400 maksimizira recall na 0,999 uz <10ms).

IVF-PQ: Recall je zakucan na **0,67** — veći **nprobe** ne može popraviti destruktivnu grešku kvantizacije!

Empirijska verifikacija tri ključne istraživačke hipoteze

✓ H1 POTVRĐENA

HNSW medijana **4,45 ms** < IVF medijana **8,56 ms**. Wilcoxon test ($W=52.432$, $p \approx 0$) dokazuje superiornost. Recall > **90%**.

● H2 DJELIMIČNO POTVRĐENA

Kompresija iznosi nevjerovatnih **40,88×** ✓ (cilj bio $\geq 4\times$), ALI pad tačnosti iznosi katastrofalnih **33,21 pp** ✗ (cilj bio < 5 pp).

✓ H3 POTVRĐENA

Unutar strogog budžeta od 2 GB, **IVF-PQ (35,8 MB)** je jedino rješenje. HNSW promašio budžet za **24 MB**.

Nema univerzalnog pobjednika – inženjerski kontekst odlučuje

[Scenarij 1: Maksimalna Tačnost]

(Slobodan memorijski budžet)

Izaberi HNSW

Recall 0,997 | 4,45 ms

[Scenarij 2: Stroga Konzistentnost]

(Predvidivost, bez jittera u sistemu)

Izaberi IVF

Recall 0,956 | P95=9ms

[Scenarij 3: Ekstremna Memorija]

(Budžet strogo ograničen ispod 2 GB)

Izaberi IVF-PQ

35,8 MB | 1,12 ms

Budući pravci: Evaluacija DiskANN-a i ScaNN struktura, te fine-tuning PQ pod-vektora.